

Politechnika Wrocławska
Wydział Geoinżynierii, Górnictwa i Geologii
Kierunek: Geoinformatyka, II rok

Rok akademicki 2024/2025
Semestr letni

Elementy fotogrametrii i teledetekcji

Laboratorium nr 2-4

Temat: Opracowanie danych pozyskanych ze skanowania laserowego cz. I, II i III

Sprawdził:
mgr inż. Aleksandra Kozłowska-Woszczycka

Wykonał: Barbasiewicz Adrian

Data realizacji ćwiczenia: 14-28.03.2025
Data dostarczenia sprawozdania: 01.05.2025

SPIS TREŚCI

1. Część I – wizualizacje wyczyszczonych chmur punktów	3
2. Część II – filtracja, wyrównanie, łączenie, wizualizacja	7
3. Część III – klasyfikacja Canupo	19
4. Wnioski.....	25

Sprawozdanie zawiera ...9... ponumerowanych kart.

1. Część I – wizualizacje wyczyszczonych chmur punktów

W pierwszym etapie przetwarzania danych w programie CloudCompare zostały zaimportowane chmury punktów. Na wstępie przeanalizowałem strukturę każdej chmury i przystąpiłem do ich ręcznej edycji.

W ramach obróbki wykonałem następujące kroki:


- Przycięcie (clipping) każdej chmury punktów do interesującego obszaru (budynku) — usunąłem otoczenie, nieistotne fragmenty tła i zasięgu skanera.
- Ręczne czyszczenie — usunąłem luźne punkty, artefakty i widoczne błędy pomiarowe (np. duchy lub odbicia).

Efekty przedstawiłem w postaci wizualizacji oraz tabeli z liczbą punktów na każdym etapie.


Wizualizacje wyczyszczonych chmur punktów

Na poniższych rysunkach przedstawiono wyczyszczone chmury punktów dla wszystkich sześciu stanowisk pomiarowych:


- Fot. 1–3: Chmury punktów z Piętra II dla stanowisk 1, 2 i 3
- Fot. 4–6: Chmury punktów z Piętra III dla stanowisk 1, 2 i 3




Fot. 1. Wyczyszczona chmura punktów Piętro 2 stanowisko 1




Fot. 2. Wyczyszczona chmura punktów Piętro 2 stanowisko 2




Fot. 3. Wyczyszczona chmura punktów Piętro 2 stanowisko 3



Fot. 4. Wyczyszczona chmura punktów Piętro 3 stanowisko 1



Fot. 5. Wyczyszczona chmura punktów Piętro 3 stanowisko 2




Fot. 6. Wyczyszczona chmura punktów Piętro 3 stanowisko 3

Piętro/stanowisko	Liczba pkt. przed edycją	Liczba pkt. po przycięciu	Liczba pkt. po czyszczeniu
II stanowisko 1	9554883	8244662	7982125
II stanowisko 2	8712217	6922808	6710543
II stanowisko 3	9816515	7442413	7130847
III stanowisko 1	38116918	34213700	33582761
III stanowisko 2	9087193	6087084	5761432
III stanowisko 3	9456557	5693171	5370916

Tabela 1. Wyniki edycji chmur punktów

2. Część II – filtracja, wyrównanie, łączenie, wizualizacja

W kolejnych krokach przeprowadzono eksperymenty związane z filtracją danych — zarówno w oparciu o intensywność odbicia wiązki lasera, jak i z zastosowaniem filtra **SOR (Statistical Outlier Removal)**. Na podstawie histogramu zbadano rozkład intensywności, określono zakresy dominujących wartości oraz dokonano podziału danych według progów intensywności. Następnie przetestowano działanie filtra SOR dla różnych parametrów, analizując wpływ filtracji na geometrię i jakość chmur punktów.



Fot. 7. Histogram wartości intensywności

Filtracja na podstawie intensywności odbicia:

W analizie wykorzystano chmurę punktów z Piętra 2, stanowiska 2. Dane zawierały 6 922 808 punktów. Intensywność odbicia oznacza siłę sygnału odbitego od powierzchni w trakcie skanowania laserowego. Histogram intensywności został przedstawiony na Fot. 7.

Analiza histogramu intensywności:


- Najniższa wartość: 0.06839100
- Najwyższa wartość: 0.99877900
- Dominujące wartości: w zakresie 0.13–0.20 – odpowiadają one głównemu szczytowi histogramu
- Drugi szczyt: około 0.45–0.60 – mniejszy, ale wyraźnie zaznaczony
- Rozkład: histogram jest dwuszczytowy, wartości są nierównomiernie rozłożone
- Zakres danych: intensywność nie pokrywa całego przedziału 0–1, a jedynie wartości do ~0.7

Działanie narzędzia „Filter by Value”:

Narzędzie Filter by Value służy do selektywnego filtrowania punktów chmury na podstawie wartości skalarnej przypisanej do każdego punktu – najczęściej jest to intensywność, wysokość, nachylenie lub inne pole atrybutowe. W przypadku analizy intensywności pozwala wyodrębnić punkty o określonym zakresie odbicia wiązki lasera.

Zakres niski (ciemne punkty): 0.068–0.2:

Zakres niski intensywności, obejmujący wartości od 0.068 do 0.2, oznacza punkty, które słabo odbijają wiązkę lasera. W praktyce są to powierzchnie o niskiej refleksyjności – na przykład ciemne materiały, zacienione fragmenty sceny, elementy roślinne, takie jak liście czy trawa. Tego typu powierzchnie pochłaniają większą część energii lasera, dlatego zapisane wartości intensywności są niskie.




Fot. 8. Wyniki użycia narzędzia filter by Value (zakres niski 0.068 – 0.20)

Komentarz:

Na wizualizacji chmury po zastosowaniu tego filtra widać głównie rozproszone punkty z zewnętrznych partii budynku lub otoczenia, o niskiej jakości geometrycznej i informacyjnej.

Zakres dominujący: 0.20–0.45:

Zakres dominujący intensywności, od 0.20 do 0.45, obejmuje wartości najczęściej występujące w analizowanej chmurze punktów. Oznacza to, że większość powierzchni budynku odbija wiązkę lasera właśnie z taką siłą – są to zwykle typowe materiały budowlane o umiarkowanej refleksyjności, jak tynk, beton czy jasne drewno.




Fot. 9. Wyniki użycia narzędzia filter by Value (zakres dominujący 0.20 – 0.45)

Komentarz:

Efektem zastosowania filtra w tym zakresie jest chmura o dobrej spójności i wysokiej czytelności. Widoczne są główne elementy konstrukcyjne budynku, takie jak ściany, stropy i balustrady.

Zakres wysoki (jasne punkty): 0.45–0.998779:

Zakres wysoki intensywności, obejmujący przedział od 0.45 do 0.998779, odpowiada punktom o bardzo silnym odbiciu wiązki lasera. Występują tu jasne powierzchnie, dobrze odbijające promieniowanie, takie jak białe ściany, gładkie tynki, metalowe lub szklane elementy o dużej refleksyjności.



Fot. 10. Wyniki użycia narzędzia filter by Value (zakres wysoki 0.45-0.998779)

Komentarz:


Efekt działania filtra w tym zakresie to czysta, dobrze zdefiniowana chmura punktów, w której wyraźnie widoczne są główne elementy architektoniczne budynku. Chmura jest zwarta i szczegółowa, pozbawiona zakłóceń, co potwierdza, że wysoki zakres intensywności zawiera najbardziej reprezentatywne dane geometryczne dla modelu obiektu.

Podsumowanie filtracji intensywności


- Zakres niski (0.068–0.2) zawiera punkty o słabym odbiciu – głównie roślinność, zacienione fragmenty i elementy szumowe; chmura rozproszona, mało czytelna.
- Zakres dominujący (0.20–0.45) obejmuje najliczniejszą grupę punktów – typowe powierzchnie budynku, dobrze odwzorowana geometria i struktura obiektu.
- Zakres wysoki (0.45–0.998779) reprezentuje jasne, dobrze odbijające powierzchnie – wyraźna, czysta chmura punktów, zawierająca kluczowe elementy konstrukcyjne.
- Filtracja intensywności pozwoliła wyodrębnić różne grupy materiałów i poprawić selektywność analizy.

Funkcja SOR:

Filtr SOR (Statistical Outlier Removal) służy do usuwania punktów odstających na podstawie analizy odległości do sąsiadów. Dla każdego punktu obliczana jest średnia odległość do określonej liczby najbliższych punktów. Jeśli ta wartość przekracza globalną średnią o więcej niż zadany próg (nSigma), punkt zostaje usunięty jako szum. Filtr pozwala automatycznie oczyścić chmurę z przypadkowych, odizolowanych punktów bez utraty istotnych danych geometrycznych.




Fot. 11. Ustawienia dla filtru SOR część 1




Fot. 12. Wynik działania filtru SOR część 1

Komentarz:

Zastosowanie filtra SOR z parametrami: 20 najbliższych punktów i próg odchylenia 1.5 pozwoliło na skuteczne usunięcie punktów odstających bez utraty struktury geometrycznej obiektu. Na wizualizacji widać, że chmura punktów została oczyszczona z przypadkowych zakłóceń, a główne elementy budynku – takie jak ściany, słupy i dach – pozostały dobrze zachowane i wyraźne. Filtracja poprawiała czytelność danych, zwłaszcza w rejonach o dużym zagęszczeniu detali.



Fot. 13. Ustawienia dla filtru SOR część 2



Fot. 14. Wynik działania filtru SOR część 2


Komentarz:

Zastosowanie filtra SOR z łagodniejszymi ustawieniami (15 sąsiadów i $nSigma = 2$) pozwoliło na bardziej zachowawczą filtrację – usunięto mniej punktów odstających, dzięki czemu chmura punktów pozostała nieco pełniejsza. Na wizualizacji nadal widoczne są niektóre drobne zakłócenia, jednak struktura budynku została w całości zachowana. Taki dobór parametrów jest korzystny w przypadku chmur, w których istnieje ryzyko usunięcia cienkich lub delikatnych elementów konstrukcyjnych.


Wnioski:

Filtracja intensywności pozwala wyodrębnić różne typy powierzchni w chmurze punktów – od roślinności po jasne elementy budynku. Filtr SOR skutecznie usuwa szum i punkty odstające bez utraty struktury obiektu. Dobór parametrów ma kluczowe znaczenie – zbyt niskie wartości usuwają zbyt wiele danych, zbyt wysokie pozostawiają zakłócenia. Połączenie obu metod daje optymalne efekty oczyszczenia.


łączenie stanowisk:




Fot. 15. Stanowisko 1 – 2 piętro 2




Fot. 16. Stanowisko 1 – 3 piętro 2




Fot. 17. Stanowisko 2 – 3 piętro 2



Fot. 18. Stanowisko 1 – 2 piętro 3




Fot. 19. Stanowisko 2 – 3 piętro 3




Fot. 20. Stanowisko 1 – 3 piętro 3

Efekt złączenia pięter




Fot. 21. Piętro 2



Fot. 22. Piętro 3


Efekt złączenie piętra 2 z 3




Fot. 23. RMS



Fot. 24. Złączone piętra



Fot. 25. Złączone piętra



Fot. 26. Złączone piętra

3. Część III – klasyfikacja Canupo

Wtyczka **CANUPO** służy do automatycznej klasyfikacji chmur punktów na podstawie ich geometrii w różnych skalach. Jej głównym celem jest rozpoznawanie typów obiektów (np. podłóże, roślinność, konstrukcje) na podstawie lokalnych cech przestrzennych, niezależnie od koloru czy intensywności.

Jak działa CANUPO:


1. **Uczenie (trening):** użytkownik wskazuje przykładowe klasy (np. punkty należące do drzewa i do budynku). Na tej podstawie algorytm buduje model statystyczny oparty na analizie otoczenia punktów w wielu skalach.
2. **Klasyfikacja:** wtyczka analizuje każdy punkt chmury, obliczając lokalne cechy (np. płaskość, kulistość) i przypisuje go do jednej z wyuczonych klas.
3. **Wynik:** punkty są oznaczone zgodnie z przypisaną klasą, co pozwala łatwo rozdzielić różne elementy sceny (np. budynek od roślinności).

Do procesu treningu klasyfikatora CANUPO konieczne było przygotowanie dwóch zestawów punktów reprezentujących odrębne klasy. W tym przypadku jako **klasa 1** wybrano próbki zawierające ławki, a jako **klasa 2** – próbki podłogi. Fragmenty zostały ręcznie wyselekcjonowane z chmury punktów za pomocą narzędzia **Segment**, a następnie połączone odpowiednio w dwie osobne chmury przy użyciu opcji **Edit > Merge**. Ważne było, aby próbki miały zbliżoną liczbę, co wpływa na jakość treningu.

Trenowanie klasyfikatora wykonano przez **Plugins > CANUPO > Train classifier**, gdzie wskazano obie klasy jako dane wejściowe. Program automatycznie wyznaczył granicę podziału między klasami na podstawie cech geometrycznych punktów (analizowanych w wielu skalach). W razie potrzeby granicę można było poprawić ręcznie. Po zakończeniu treningu model został zapisany w pliku o rozszerzeniu **.prm**.

Gotowy klasyfikator zastosowano do całej przyciętej chmury punktów poprzez **Plugins > CANUPO > Classify**, gdzie załadowano zapisany wcześniej plik **.prm** i wskazano dane do analizy. Program przypisał każdemu punktowi jedną z wytrenowanych klas, co pozwoliło na automatyczną klasyfikację całej chmury.

Próba nr 1 – ławki i podłoga



Fot. 27. Ławki i podłoga liczba punktów : 700 000


Cechy geometryczne:

Ławki:

- Zakrzywiony, zamknięty lub półzamknięty kształt (okrąg/łuk)
- Wzniesione nad poziom podłogi
- Obecność pionowych i skośnych powierzchni
- Nieregularna, bardziej złożona struktura
- Wyraźne krawędzie i zmiany orientacji punktów
- Zróżnicowana gęstość i lokalna chropowatość


Podłoga:

- Płaska, pozioma powierzchnia
- Jednorodna i ciągła struktura
- Brak krawędzi i ostrych przejść
- Punkty zorientowane horyzontalnie
- Małe zróżnicowanie lokalne
- Stała, gęsta siatka punktów o równomiernym rozkładzie



Fot. 28. Fragmenty ławek i podłogi

Na przedstawionym obrazie widać proces treningu klasyfikatora CANUPO, w którym pobrałem po cztery próbki dla każdej z dwóch klas: ławka (czerwony) oraz podłoga (niebieski). Widoczne skupiska punktów po obu stronach granicy świadczą o tym, że próbki zostały dobrze dobrane, a klasyfikator potrafi odróżnić ławki od podłogi na podstawie ich cech geometrycznych.



Fot. 29. ławki i podłoga po zastosowaniu CANUPO

Komentarz do zastosowania CANUPO dla podłogi i ławki:


Na przedstawionym obrazie widoczny jest wynik klasyfikacji wykonanej za pomocą wtyczki **CANUPO**. Punkty zaklasyfikowane jako **ławki** oznaczone są kolorem **czerwonym**, a punkty przypisane do **podłogi** kolorem **niebieskim**.

Mimo że ogólna forma obiektów została rozpoznana, klasyfikacja nie jest w pełni poprawna. Część punktów podłogi została błędnie zakwalifikowana jako ławka – szczególnie widoczne są czerwone plamy na płaskich, poziomych powierzchniach. Może to wynikać z:

- zbyt małej liczby próbek treningowych,
- zbyt dużej różnorodności geometrii w klasie ławki (np. uwzględnione były różne kształty),
- niewystarczającego rozróżnienia cech geometrycznych między klasami.

W efekcie granica między klasami została wyznaczona zbyt ogólnie, przez co klasyfikator nadinterpretował fragmenty podłogi jako część złożonej struktury ławek.

Próba nr 2 – barierki i ściany



Fot. 30. Barierki i ściany liczba punktów: 627 429


Cechy geometryczne:

Ściana:

- Płaska, jednolita powierzchnia
- Pionowa orientacja
- Duża grubość i zwarta struktura
- Gęste i równomierne rozmieszczenie punktów
- Brak pustych przestrzeni
- Niska lokalna zmienność kształtu

Barierka:

- Cienkie, smukłe elementy (pręty)
- Powtarzalna, rytmiczna struktura
- Duża liczba pustych przestrzeni między prętami
- Nieregularne lub rozproszone rozmieszczenie punktów
- Wyraźne granice i ostre krawędzie
- Wysoka lokalna zmienność geometrii (dużo detalu na małej powierzchni)



Fot. 31. Barrierki i ściany po zastosowaniu CANUPO

Komentarz do zastosowania CANUPO dla barierki i ścian:

Wynik klasyfikacji przedstawiony na obrazie wygląda zdecydowanie lepiej niż w poprzednim przypadku. Obiekty zostały rozdzielone wyraźnie i zgodnie z ich strukturą – **barierka** została poprawnie zaklasyfikowana do klasy **czerwonej**, a **ściany** i otaczające je elementy do klasy **niebieskiej**.

Cienkie, regularne pręty barierki są dobrze rozpoznawalne i wyraźnie oddzielone od masywnych, pionowych płaszczyzn ścian. Świadczy to o tym, że klasyfikator CANUPO skutecznie odróżnił te dwa typy obiektów na podstawie ich cech geometrycznych. Prawdopodobnie pomogła w tym wyraźna różnica w grubości, gęstości punktów oraz lokalnej złożoności.

To pokazuje, że para obiektów **barierka–ściana** jest bardziej rozróżnialna geometrycznie niż np. ławka–podłoga, a sam klasyfikator działa lepiej, gdy klasy są dobrze zdefiniowane i jednoznacznie różnią się kształtem.

4. Wnioski

- Proces przycinania i czyszczenia chmury punktów pozwolił mi skutecznie usunąć zbędne dane, co znacząco poprawiło jakość dalszej analizy oraz zmniejszyło objętość chmury, dzięki czemu praca w programie była bardziej płynna.
- Filtracja na podstawie intensywności odbicia wiązki lasera pokazała, że odpowiedni dobór zakresów intensywności pozwala na oddzielenie różnych obiektów. Zauważyłem jednak, że niewłaściwe ustawienie progów może prowadzić do utraty ważnych danych lub pozostawienia szumu.
- Po zastosowaniu filtra SOR zauważyłem, że chmura punktów stała się wyraźnie oczyszczona i gładza. Musiałem jednak uważać na dobór parametrów – zbyt mocne filtrowanie powodowało usunięcie niektórych potrzebnych detali.
- Podczas wyrównywania chmur punktów za pomocą narzędzia Align zauważyłem, że dokładność dopasowania zależy od precyzji w wyznaczeniu punktów wspólnych. Błąd średniokwadratowy był wyraźnie mniejszy, gdy punkty były dobrze dobrane.
- W trakcie pracy z klasyfikatorem CANUPO przekonałem się, że bardzo ważne jest staranne przygotowanie próbek do treningu. Dobrze wybrane fragmenty punktów pozwoliły na poprawne rozróżnienie obiektów o różnych cechach geometrycznych. Zauważyłem, że klasyfikacja najlepiej działała dla par takich jak ściana i barierka, gdzie różnice geometryczne były wyraźne. W przypadku klasyfikacji ławki i podłogi pojawiały się błędy, co pokazuje, jak duży wpływ na skuteczność ma właściwe dobranie klas treningowych.